
Aprendizagem Automática

FICHA N. 4

ENUNCIADO

Nome: Pedro Miguel Pereira Henriques

Número: A45415

ATENÇÃO: Fixa de respostas múltiplas. Só uma única resposta em cada alínea está correta. Cada alínea vale 2 valores. Respostas erradas descontam 0.5 valores.

1. No ficheiro `A45415_Q001_data.p`, encontra-se um conjunto de dados bidimensionais divididos em duas classes $\Omega = \{\varpi_0, \varpi_1\}$ (negativos e positivos). Há duas variáveis num dicionário: \mathbf{x} é uma matriz de dados, e \mathbf{y} é um array com as classes dos dados. Considere o seguinte modelo linear de classificação:

$\hat{y} = \mathbf{w}^\top \mathbf{x} = w_0 + w_1 x_1 + w_2 x_2$, com $\mathbf{x} \in \varpi_1$ para $\hat{y} \geq 0$, e para $\mathbf{w} = [w_0, w_1, w_2]^\top$ e $\mathbf{x} = [1, x_1, x_2]^\top$.

Considere ainda que o vetor \mathbf{w}_{MSE} é o vetor de pesos que minimiza o erro quadrático médio deste conjunto: $\mathcal{E} = \frac{1}{N} \sum_{n=1}^N (y[n] - \hat{y}[n])^2$, onde N é o número total de pontos, e $n = 1, \dots, N$. As saídas desejadas são: $y[n] = -1$ para $\mathbf{x}[n] \in \varpi_0$ e $y[n] = +1$ para $\mathbf{x}[n] \in \varpi_1$.

- (a) Considere o classificador com vetor de pesos, \mathbf{w}_{MSE} , que minimiza o erro quadrático médio do conjunto.
 - i. O vetor que minimiza o erro quadrático médio é $\mathbf{w}_{\text{MSE}} = [-0.001, 0.292, 0.041]$.
 - ii. O erro absoluto médio é igual a 0.637.
 - iii. Todas as respostas anteriores.
 - iv. Nenhuma das respostas anteriores.
 - (b) Considere o classificador com o seguinte vetor de pesos $\mathbf{w} = [0.00, 0.53, 0.85]$.
 - i. A taxa de falsos alarmes é de 0.368.
 - ii. O número de erros na classe ϖ_0 é de 311.
 - iii. O valor da precisão é de 0.788.
 - iv. O número total de acertos é de 1643.
 - (c) Considere o classificador com o seguinte vetor de pesos $\mathbf{w} = [0.00, 0.79, 0.61]$.
 - i. O valor do *recall* é de 0.949.
 - ii. O número de acertos na classe ϖ_0 é de 643.
 - iii. Todas as respostas anteriores.
 - iv. Nenhuma das respostas anteriores.
2. No ficheiro `A45415_Q002_data.p` encontra-se disponível uma variável independente \mathbf{x} e uma variável dependente \mathbf{y} . Pretende-se estimar a variável \mathbf{y} através de uma regressão polinomial da variável \mathbf{x} , minimizando o erro quadrático médio.

- (a) Considere o conjunto de treino composto pelo “fold” 0, e o conjunto de teste composto pelo “fold” 1. Considere ainda que, através da minimização do erro quadrático médio do conjunto de treino, se estimou um modelo regressão polinomial de 3ª ordem: $\hat{y} = w_0 + w_1x + w_2x^2 + w_3x^3$.
- Arredondando a zero casas decimais, o valor de w_0 é -10.
 - No conjunto de treino, o coeficiente de determinação, R^2 , é igual a 0.69.
 - Todas as respostas anteriores.
 - Nenhuma das respostas anteriores.
- (b) Considere o conjunto de treino composto pelo “fold” 0, e o conjunto de teste composto pelo “fold” 1. Considere ainda que, através da minimização do erro quadrático médio do conjunto de treino, se estimou um modelo regressão polinomial de 4ª ordem: $\hat{y} = w_0 + w_1x + w_2x^2 + w_3x^3 + w_4x^4$.
- No conjunto de teste, o erro quadrático médio é igual a 570.74.
 - No conjunto de treino, o erro quadrático médio é igual a 0.03.
 - Todas as respostas anteriores.
 - Nenhuma das respostas anteriores.
- (c) Considere que \hat{y}_A é o modelo de regressão polinomial de 4ª ordem obtido minimizando o erro quadrático médio com os primeiros 81 pontos do conjunto. Considere ainda que \hat{y}_B é modelo de regressão polinomial de 4ª ordem obtido minimizando o erro quadrático médio com o “fold” 0. Finalmente, considere que o modelo \hat{y}_A é avaliado com os últimos 81 pontos do conjunto, e que \hat{y}_B é avaliado com os dados do “fold” 1.
- Ambos os modelos obtêm resultados comparáveis.
 - Os resultados do modelo \hat{y}_B são devidos à divisão sub-ótima dos dados.
 - 4 é uma ordem polinomial demasiada elevada para modelar os dados.
 - O modelo \hat{y}_B apresenta melhores resultados que \hat{y}_A .
3. Considere o conjunto “diabetes” disponível em `sklearn.datasets` (usar a função `load_diabetes()`). Pretende-se estimar e avaliar modelos de regressão polinomial com os dados deste conjunto: use as primeiras 254 amostras para treino e as restantes para teste.
- (a) Considere que utiliza função Lasso (sub-módulo `linear_model` do `sklearn`) para uma regressão polinomial de 3ª ordem dos dados de treino. Instancie o regressor somente com os seguintes parâmetros:
`Lasso(random_state=42, alpha=0.01)`
- No conjunto de teste, o erro quadrático médio é igual a 2890.32.
 - No conjunto de treino, o coeficiente de determinação, R^2 , é igual a 0.52.
 - Todas as respostas anteriores.
 - Nenhuma das respostas anteriores.
- (b) Considere o modelo de regressão polinomial de 2ª ordem que minimiza o erro quadrático médio no conjunto de treino.
- No conjunto de teste, o coeficiente de determinação, R^2 , é igual a 0.513.
 - No conjunto de teste, o erro quadrático médio é igual a 9782.80.

- iii. Todas as respostas anteriores.
 - iv. Nenhuma das respostas anteriores.
- (c)
- i. O número de coeficientes, incluindo w_0 , numa regressão polinomial de ordem 2, é igual a 66.
 - ii. O número de coeficientes, incluindo w_0 , numa regressão polinomial de ordem 4, é igual a 993.
 - iii. Todas as respostas anteriores.
 - iv. Nenhuma das respostas anteriores.