

Classificação de Críticas de Cinema do IMDb

Docente: Gonçalo Marques

Desenvolvido por: Ana Oliveira - A39275



Limpeza dos Dados

Limpeza dos Dados (exemplo 1)

Crítica Original (182 palavras)

This interesting Giallo boosts a typical but still thrilling plot and a really sadistic killer that obviously likes to hunt his victims down before murdering them in gory ways.

br/>
br/>
br/>
Directed by Emilio P. Miraglia who, one year earlier, also made the very interesting "La Notte che Evelyn Usci della Tomba" (see also my comment on that one), the film starts off a little slow, but all in all, no time is wasted with unnecessary sub plots or sequences.

br/>
This film is a German-Italian coproduction, but it was released in Germany on video only in a version trimmed by 15 minutes of plot under the stupid title "Horror House". At least the murder scenes, which will satisfy every gorehound, are fully intact, and the viewer still gets the killer's motive at the end. But the Italian version containing all the footage is still the one to look for, of course.

br/>
A convincing Giallo with obligatory twists and red herrings, "La Dama Rossa Uccide Sette Volte" is highly recommended to Giallo fans and slightly superior to Miraglia's above mentioned other thriller.

Crítica Sem Mudanças de Linha (179 palavras)

This interesting Giallo boosts a typical but still thrilling plot and a really sadistic killer that obviously likes to hunt his victims down before murdering them in gory ways. Directed by Emilio P. Miraglia who, one year earlier, also made the very interesting "La Notte che Evelyn Usci della Tomba" (see also my comment on that one), the film starts off a little slow, but all in all, no time is wasted with unnecessary sub plots or sequences. This film is a German-Italian coproduction, but it was released in Germany on video only in a version trimmed by 15 minutes of plot under the stupid title "Horror House". At least the murder scenes, which will satisfy every gorehound, are fully intact, and the viewer still gets the killer's motive at the end. But the Italian version containing all the footage is still the one to look for, of course. A convincing Giallo with obligatory twists and red herrings, "La Dama Rossa Uccide Sette Volte" is highly recommended to Giallo fans and slightly superior to Miraglia's above mentioned other thriller.

Limpeza dos Dados (exemplo 2)

Crítica Original (182 palavras)

Limpeza alfanumérica (112 palavras)

They really can t get stupider than this film dealing with $\underline{3}$ losers who try to capture the college spirit during the annual spring break festivities at many of our higher schools of learning The problem is that these losers try to do this $\underline{15}$ years after their college years when one is assigned to watch over the daughter of a woman senator being groomed to be the next vice president Trouble is that her daughter is anything but popular but of course she comes out of all that The girls go through drunken rages exotic dancing and other absolute nonsense It really can t get much worse than this awful film

Limpeza alfabética (110 palavras)


They really can t get stupider than this film dealing with losers who try to capture the college spirit during the annual spring break festivities at many of our higher schools of learning The problem is that these losers try to do this years after their college years when one is assigned to watch over the daughter of a woman senator being groomed to be the next vice president Trouble is that her daughter is anything but popular but of course she comes out of all that The girls go through drunken rages exotic dancing and other absolute nonsense It really can t get much worse than this awful film

Limpeza dos Dados

(comparação)



Maior vocabulário: Sem limpeza Menor vocabulário: Limpeza Alfabética



Stop Words

- Palavras com maior frequência na utilização do inglês.
 - Ex: "a" e "the"
- Usadas num contexto genérico e não específico;
- Não são úteis para a análise de críticas.

Tamanho do dicionário: 28521

Mean cross-validation accuracy: 0.83

Tamanho do dicionário: 28509

Mean cross-validation accuracy: 0.85

- Impacto vocabulário: reduzido;
- Impacto esperado na classificação: elevado.

Tokenização Porter Stemmer Snowball Stemmer Lancaster Stemmer

- Processo que reduz palavras à sua raiz.
- Não considera a linguística. Ou seja, pode gerar tokens linguisticamente incorretos ou palavras que não existem.
 - Ex: "car" e "care" ambas são convertidas para "car".
- Foram avaliados 3 formas de tokenização:
 - Porter Stemmer

Mais usado

Simples

Rápido de executar

Suporta apenas inglês

Snowball Stemmer

Versão melhorada do Porter

Mais complexo

Mais lento

Lancaster Stemmer

► Abordagem mais agressiva

Pode levar a over-stemming

Suporta apenas inglês

Tamanho do dicionário: 19613

Mean cross-validation accuracy: 0.84

Tamanho do dicionário: 19316

Mean cross-validation accuracy: 0.84

Tamanho do dicionário: 16222

Lematização WordNetLemmatizer

- Processo identifico à tokenização
- Considera a composição natural das palavras
 - Ex: "car" e "care" são convertidos para a sua forma canónica.
- Palavras n\u00e3o perdem o contexto.

Tamanho do dicionário: 24272 Mean cross-validation accuracy: 0.85

• WordNetLemmatizer é o módulo da biblioteca NLTK que é utilizado e que permite efetuar a lematização.

Tokenização Vs Lematização



Maior vocabulário: Sem tokenização/ lematização




Menor vocabulário: Lancaster Stemmer



Melhor performance:
Porter Stemmer
Lematização



Pior Performance: Lancaster Stemmer Snowball Stemmer



Limpeza dos Dados (conclusões)

- Informação numérica nas críticas não é a mais importante a ser mantida;
- Limpeza alfabética diminui o tamanho do vocabulário;
- Significado associado ao contexto da crítica é importante para discriminar as várias críticas.
- Embora lematização não diminua muito o tamanho do vocabulário mantém o contexto.


Processo escolhido:

- 1. Remoção de mudanças de linha
- 2. Limpeza alfabética
- 3. Stop Words
- 4. Lematização NetWordLemmatizer




Extração de Características

TFIDF
Min_df e Max_df




- Melhores valores para min_df = [3, 4, 5]
- Melhores valores para max_df = [0.55, 0.65, 0.75]

TFIDF ngram_range



Melhores valores para ngram_range = [(1, 1), (1, 2), (1, 3)]

TFIDF token_pattern



Melhores valores para token_pattern = r'\b\w{3,}\b'

TFIDF (conclusões)

TFIDF com parâmetros default:


Score Treino: 0.87 Score Teste: 0.362


Parametros escolhidos:

- min_df=3
- max_df=0.75
- ngram_range=(1,3)
- token_pattern=r'\b\w{3,}\b'
- TFIDF parametrizado:

Score Treino: 0.894 Score Teste: 0.36

Classificação Binária







Distribuição uniforme das críticas positivas e negativas



Dados de treino 2/3 das críticas




Dados de teste
1/3 das críticas


Logistic Regression

▶ Logistic Regression com parâmetros default:

- Parametrização:
 - ► C=10
 - penalty='l2'
 - solver='liblinear'
 - ▶ tol=1e-3
- Treino
 - Score: 0.999
 - Número de erros: 46
 - ▶ F1-Score: 1.00




- Teste
 - Score: 0.905
 - Número de erros: 1572
 - ▶ F1-Score: 0.91




Máquina de Suporte Vetorial Linear (LinearSVC)

▶ LinearSVC com parâmetros default:

- Parametrização:
 - ► C=0.01
 - loss='hinge'
 - ▶ tol=0.001
- Treino
 - Score: 0.987
 - Número de erros: 432
 - ▶ F1-Score: 0.99




- Teste
 - Score: 0.905
 - Número de erros: 1585
 - ▶ F1-Score: 0.90




Máquina de Suporte Vetorial (SVC)

SVC com parâmetros default:

- Parametrização:
 - ► C=10
 - degree=1
 - ▶ gamma=10
 - kernel='poly'
- Treino
 - Score: 0.987
 - Número de erros: 431
 - ▶ F1-Score: 0.99



- Teste
 - > Score: 0.905
 - Número de erros: 1589
 - ▶ F1-Score: 0.90




Naive Bayes (MultinomialNB)

MultinomialNB com parâmetros default:


Mean cross-validation accuracy: 0.86

- Parametrização:
 - ▶ alpha=0.1
- Treino
 - Score: 0.951
 - Número de erros: 1649
 - ▶ F1-Score: 0.95




Teste

- Score: 0.885
- Número de erros: 1915
- ▶ F1-Score: 0.89



Classificador Binário (conclusões)







Melhor Performance:
Logistic Regression
LinearSVC
SVC


Menos Erros: Logistic Regression




Pior Performance: Naive Bayes Mais erros: Naive Bayes

ılı.

Classificação Multiclasse







Mais amostras de umas classes do que de outras



Dados de treino
1/2 número
mínimo amostras
de todas as classes




<u>Dados de teste</u> Restantes críticas


Logistic Regression

Logistic Regression com parâmetros default:

- Parametrização:
 - ► C=100
 - multi_class='ovr'
 - solver='saga'
 - ▶ tol=0.001
- Treino
 - Score: 1.0
 - Número de erros: 1




- Teste
 - Score: 0.398
 - Número de erros: 8009




Máquina de Suporte Vetorial Linear (LinearSVC)

LinearSVC com parâmetros default:

- Parametrização:
 - ► C=0.01
 - loss='hinge'
 - ▶ tol=0.001
- Treino
 - Score: 0.975
 - Número de erros: 903



- Teste
 - Score: 0.518
 - Número de erros: 6418




Máquina de Suporte Vetorial (SVC)

SVC com parâmetros default:


Mean cross-validation accuracy: 0.36

- Parametrização:
 - ► C=10
 - degree=1
 - > gamma=10
 - kernel='poly'
- Treino
 - Score: 1.0
 - Número de erros: 1



Teste

- Score: 0.39
- Número de erros: 8121




Naive Bayes (MultinomialNB)

MultinomialNB com parâmetros default:


Mean cross-validation accuracy: 0.33

- Parametrização:
 - ▶ alpha=0.1
- Treino
 - Score: 0.992
 - Número de erros: 306



Teste

- Score: 0.37
- Número de erros: 8392



Classificador Multiclasse (conclusões)







Menos Erros: LinearSVC



Pior Performance: Naive Bayes



Mais erros: Naive Bayes